

Actividad 2. Calidad, drift y anomalías

Descargar el dataset de salarios en data science disponible en Kaggle: <https://www.kaggle.com/datasets/arnabchaki/data-science-salaries-2023> y luego aplicar los siguientes pasos:

Preparar los datos

Dividir el dataset en 2 períodos:

- Referencia: años 2020-2021
- Actual: años 2022-2023

Calidad y drift

- a. Elegir 3-4 variables relevantes (por ej. salary_in_usd, experience_level, remote_ratio, company_size) y aplicar al menos 3 chequeos de calidad a elección.
- b. Sobre las mismas variables, calcular PSI comparando la distribución de referencia vs. la actual.
- c. Para cada variable, indicar si hay drift y a qué tipo podría corresponder. Establecer un umbral y justificar la conclusión a partir del valor de PSI y de dicho umbral.
- d. Con el modelo entrenado en la Actividad 1: si detectaron drift, qué estrategia de las vistas en clase (reentrenamiento, feature engineering, ensamble) aplicarías? Justificar la elección.

Detección de anomalías

- a. Aplicar Isolation Forest y LOF sobre el dataset, usando variables relevantes.
- b. Identificar al menos un registro marcado como anómalo por alguno de los dos métodos.
- c. Para ese registro: ¿es un outlier univariado o multivariado? Justificar mirando los valores reales del registro.
- d. ¿Isolation Forest y LOF coinciden en marcarlo como anómalo? Si no coinciden, ¿a qué se debe la diferencia (repasar la lógica de cada uno)?

Forma de entrega

Enlace a una notebook en un repositorio de acceso público. *Lo importante es que el código esté ejecutado* (que muestre la salida).

Evaluación

- Se evaluará que se haya respetado la consigna y que haya una interpretación adecuada de los resultados.
- Cada respuesta debe estar justificada mediante evidencia obtenida a partir de las herramientas y métricas utilizadas.