


Actividad 3. Reducción de dimensionalidad y clustering

Crear un pipeline de ML no supervisado para explorar la estructura de un dataset, identificar patrones y grupos, y extraer conocimiento útil de los datos.



1. Selección del dataset

Elegir un dataset entre los siguientes:

NOMBRE	DESCRIPCIÓN	TARGET
Communities and crime	Cada fila del dataset representa una comunidad específica de los Estados Unidos en la década de 1990. El dataset tiene 127 variables socioeconómicas, demográficas y policiales normalizadas.	Problema de regresión: tasa de crímenes violentos per cápita (ViolentCrimesPerPop) Problema de clasificación: se podría binarizar la target (por ejemplo, definir si es True o False dependiendo de un umbral de criminalidad) o discretizar en niveles de criminalidad.
Human Activity Recognition Using Smartphones	Cada fila corresponde a una ventana temporal de 2,56 segundos de una persona realizando una actividad	Actividades (etiquetas): - 1 WALKING - 2 WALKING_UPSTAIRS - 3 WALKING_DOWNSTAIRS

	cotidiana (caminar, subir escaleras, etc.). Las actividades están representadas mediante 561 características extraídas de las señales del acelerómetro y el giroscopio de un smartphone.	- 4 SITTING - 5 STANDING - 6 LAYING
Fashion MNIST (*)	Cada fila corresponde a una Imagen de 28x28. Estas imágenes correspondientes a prendas (similar al dataset MNIST de dígitos)	Prendas (etiquetas): 0 T-shirt/top 1 Trouser 2 Pullover 3 Dress 4 Coat 5 Sandal 6 Shirt 7 Sneaker 8 Bag 9 Ankle boot
20 newsgroup preprocessed (**)	Cada observación corresponde a una noticia. Los documentos se encuentran agrupados en 20 categorías correspondientes a diferentes tópicos.	Tópicos (etiquetas): alt.atheism comp.graphics comp.os.ms-windows.misc comp.sys.ibm.pc.hardware comp.sys.mac.hardware comp.windows.x misc.forsale rec.autos rec.motorcycles rec.sport.baseball rec.sport.hockey sci.crypt sci.electronics sci.med sci.space soc.religion.christian talk.politics.guns talk.politics.mideast talk.politics.misc talk.religion.misc

(*) Requiere conocimientos básicos para trabajar con imágenes, visualizarlas y representarlas como datos.

(**) Requiere conocimientos básicos de procesamiento de texto y generación de embeddings.

2. Análisis exploratorio y preprocesamiento (obligatorio, 1 punto)

- Descripción del dataset. ¿Qué representa cada observación?
- Análisis y visualización de tipos de datos (numéricos, categóricos, imágenes, etc.).
- Obtención de una representación adecuada, si corresponde (por ej. embeddings en el caso de texto).
- Tratamiento de valores faltantes y normalización/estandarización si la técnica a aplicar lo requiere.

3. Reducción de dimensionalidad y clustering (obligatorio, 7 puntos)

- a) Aplicar reducción de dimensionalidad para obtener una representación compacta de los datos, conservando la mayor cantidad de información posible.
- b) Entrenar al menos dos algoritmos de clustering diferentes sobre la representación obtenida mediante reducción de dimensionalidad.

Importante: la variable target no debe utilizarse para realizar la reducción de dimensionalidad ni para construir los clusters. Solo se debe usar para el análisis e interpretación posterior de los grupos.

- c) Evaluar y comparar los resultados de los distintos algoritmos de clustering. Analizar las diferencias entre las soluciones obtenidas y determinar cuál resulta más adecuada para los datos, utilizando métricas de evaluación y/o visualizaciones de los clusters. Justificar la selección de una de las soluciones para el análisis posterior.
- d) Interpretar los clusters resultantes del algoritmo de clustering seleccionado. ¿Qué estructura de los datos está capturando el clustering? ¿Qué información aportan los grupos encontrados?:
 - En problemas de **clasificación**: analizar la composición de cada cluster según las categorías conocidas. Por ejemplo, determinar qué clases predominan en cada cluster, qué clases tienden a agruparse y cuáles presentan mayor solapamiento. ¿Existe una correspondencia entre los clusters encontrados y las categorías reales? ¿Los grupos identificados presentan una interpretación coherente con el dominio?
 - En problemas de **regresión**: analizar cómo se distribuye la variable target entre los clusters. Por ejemplo, comparar sus medias, medianas, dispersión o distribución. No se espera necesariamente que los clusters expliquen la variable target; el objetivo es determinar si existen diferencias en target que permitan caracterizar o interpretar los grupos.

En todos los casos:

- Complementar el análisis con observaciones representativas de cada cluster.
- Describir qué características distinguen a los diferentes grupos.
- Explicar qué información aportan los clusters sobre los datos y el problema analizado.

4. Visualización e interpretación con UMAP (opcional, 2 puntos)

A partir de los datos originales, aplicar UMAP para obtener una representación bidimensional de los datos y visualizar su estructura. Analizar e interpretar los patrones observados, por ejemplo, regiones diferenciadas, separaciones, zonas de mayor o menor densidad, posibles agrupamientos o puntos aislados. ¿Qué información aporta esta representación y qué conclusiones pueden extraerse a partir de ella?

Forma de entrega

Enlace a una notebook en un repositorio de acceso público. *Lo importante es que el código esté ejecutado* (que muestre la salida).

La notebook debe contener el storytelling: hipótesis, el proceso de selección de técnicas, las visualizaciones y las conclusiones de dominio obtenidas.

Evaluación

- Se evaluará que se haya respetado la consigna y que haya una interpretación adecuada de los resultados.
- No se evaluará haber realizado un EDA o preprocesamiento exhaustivos. El foco está en el análisis e interpretación de los resultados.